

การจำแนกสายพันธุ์ถั่วพิสตาชิโอด้วยเทคนิคการเรียนรู้ของเครื่อง

Pistachio Classification Using Machine Learning

อภิญญา ทูลแรง และ จิรโรจน์ ตอสะสุกุล

Apinya Thunraeng and Jiraroj Tosasukul

ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์ มหาวิทยาลัยนครสวรรค์ จังหวัดพิษณุโลก 65000

บทคัดย่อ

การวิจัยนี้มีวัตถุประสงค์เพื่อจำแนกสายพันธุ์ของถั่วพิสตาชิโอ 2 ชนิด ได้แก่ เคียร์มีซีและเซียร์ต โดยใช้เทคนิคการเรียนรู้ของเครื่อง ข้อมูลที่ใช้ในการจำแนกสายพันธุ์ของถั่วพิสตาชิโอประกอบด้วยตัวแปรอิสระจำนวน 16 ตัวแปร และตัวแปรตามจำนวน 1 ตัวแปร ใช้ข้อมูลจากเว็บไซต์ของมูร์ต เคอคลีโอ วิธีการวิจัย คือ เปรียบเทียบประสิทธิภาพของเทคนิคการจำแนกสายพันธุ์ถั่วพิสตาชิโอ ทั้ง 4 เทคนิค ได้แก่ เพื่อนบ้านใกล้ที่สุด ซัพพอร์ตเวกเตอร์แมชชีน ต้นไม้ป่าสุ่มและเอ็กซ์ตรีมเกรเดียนต์บูสติง โดยพิจารณาประสิทธิภาพของเทคนิคด้วย ค่าความแม่นยำ ค่าการเรียกคืนและค่าประสิทธิภาพโดยรวม เป็นเกณฑ์ในการพิจารณาผลการจำแนกสายพันธุ์ของถั่วพิสตาชิโอทั้ง 2 สายพันธุ์ ผลการศึกษาพบว่า เทคนิคต้นไม้ป่าสุ่มมีประสิทธิภาพดีที่สุดโดยให้ค่าการเรียกคืนเท่ากับ 0.9106 ค่าประสิทธิภาพโดยรวมเท่ากับ 0.8871 ความแม่นยำเท่ากับ 0.8671 สูงที่สุดเมื่อเทียบกับเทคนิคอื่น ๆ แสดงให้เห็นถึงความสามารถของเทคนิคในการจำแนกสายพันธุ์ถั่วพิสตาชิโอได้อย่างแม่นยำสูง ตัวแบบที่ได้จากเทคนิคต้นไม้ป่าสุ่มสามารถนำมาใช้เป็นแนวทางสำหรับการจำแนกสายพันธุ์ถั่วพิสตาชิโอ ในภาคอุตสาหกรรมอาหารในอนาคต

คำสำคัญ : การจำแนก, ถั่วพิสตาชิโอ, การเรียนรู้ของเครื่อง

Abstract

This research aimed to classify two varieties of pistachios, Kirmizi and Siirt, using machine learning techniques. The dataset used for pistachio variety classification consisted of 16 independent variables and one dependent variable, obtained from the dataset created by Murat Köklü. The study compared the performance of four classification techniques: K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Random Forest (RF), and Extreme Gradient Boosting (XGBoost). The performance of each technique was evaluated using accuracy, recall, and overall efficiency (F1-score) as the key performance indicators for classifying the two pistachio varieties. The results revealed that the Random Forest technique achieved the best performance, with a recall of 0.9106, an F1-score of 0.8871, and an accuracy of 0.8671, which were the highest among all the tested models. These findings demonstrate the high capability of the Random Forest technique in accurately classifying pistachio varieties. The model developed using the Random Forest technique can serve as a guideline for pistachio variety classification in the food industry for future applications in production and research.

Keywords : Classification, Pistachio, Machine Learning

*Corresponding author. E-mail : apinyat66@nu.ac.th

บทนำ

ความสำคัญและที่มาของปัญหา

ถั่วพิสตาชิโอเป็นถั่วที่ได้รับความนิยมมากพอสมควรในปัจจุบัน เนื่องจากมีรสชาติอร่อยและดีต่อสุขภาพ ถั่วพิสตาชิโอเป็นถั่วชนิดไม่ยืนต้นในวงศ์ Anacardiaceae (กลุ่มเดียวกับมะม่วงทิมพานต์) มีต้นกำเนิดในอิหร่าน พบได้ใน ซีเรีย เลบานอน ตุรกี กรีซ คีร์กีซสถาน เติร์กเมนิสถาน อินเดีย ปากีสถาน อียิปต์ เกาหลีใต้ และอาจจะอยู่ในอัฟกานิสถาน ลักษณะของถั่วพิสตาชิโอจะมีเปลือกสีขาวหุ้ม เนื้อข้างในเป็นสีเขียวเหลืองอมม่วงๆ จัดอยู่ในตระกูลถั่วเปลือกแข็ง แม้ว่าจะมีไขมันค่อนข้างมาก แต่เป็นไขมันประเภทที่ให้ผลดีต่อสุขภาพ สามารถลดระดับไขมันในเลือด ลดความเสี่ยงต่อโรคหัวใจและหลอดเลือดลงได้เมื่อมีพฤติกรรมการบริโภคที่ดีร่วมด้วย และถั่วพิสตาชิโอยังมีประโยชน์ในการช่วยลดคอเลสเตอรอล สำหรับผู้ที่มีปัญหาเกี่ยวกับคอเลสเตอรอลควรเลือกทานถั่วพิสตาชิโอ เพราะเป็นแหล่งอาหารที่ดีที่สุดสำหรับกรดไขมันไม่อิ่มตัว เช่น กรดโอเลอิก และสารต้านอนุมูลอิสระที่มีประสิทธิภาพในการลดไขมันชนิดเลวและเสริมสร้างไขมันชนิดดี (มูลนิธิหัวใจแห่งประเทศไทยในพระบรมราชูปถัมภ์, 2021)

นอกจากนี้ข้อมูลของ Food and Agriculture Organization (FAOSTAT, 2023) ระบุว่าถั่วพิสตาชิโอเป็นพืชเศรษฐกิจที่มีมูลค่าการค้าสูงทั่วโลก โดยมีประเทศผู้ผลิตหลักได้แก่ อิหร่าน สหรัฐอเมริกา และตุรกี ซึ่งรวมกันคิดเป็นสัดส่วนกว่า 85 ถึง 90 เปอร์เซ็นต์ของการผลิตทั้งหมดของโลก ทั้งนี้ในปี 2022 มีมูลค่าการส่งออกถั่วพิสตาชิโอทั่วโลกมากกว่า 3.9 พันล้านเหรียญสหรัฐ สะท้อนให้เห็นถึงความสำคัญทางเศรษฐกิจของพืชชนิดนี้ในตลาดโลก

ปัจจุบันการนำเข้าถั่วพิสตาชิโอในไทยนั้นราคาสูง ซึ่งมูลค่าของถั่วพิสตาชิโอนั้นจะแตกต่างกันตามแต่ละสายพันธุ์จึงจำเป็นต้องมีวิธีการและเทคโนโลยีใหม่ ๆ ในการจำแนกสายพันธุ์พิสตาชิโอต่าง ๆ มูลค่าของถั่วพิสตาชิโอแต่ละสายพันธุ์ไม่เท่ากัน ขึ้นอยู่กับคุณภาพ ลักษณะทางกายภาพและความนิยมในตลาด โดยสายพันธุ์ที่มีคุณภาพสูง จะมีความต้องการสูงในตลาด การพัฒนาวิธีการและเทคโนโลยีในการจำแนกสายพันธุ์จึงมีความสำคัญเพื่อรักษามาตรฐานคุณภาพและมูลค่าของผลิตภัณฑ์ ทั้งนี้งานวิจัยของ นิซารีย์ ศรีบุญจันดี (2566) ซึ่งให้เห็นว่า ลักษณะทางกายภาพของเมล็ด เช่น ขนาด ความยาวแกนหลัก ความยาวแกนรอง ความกลมของเมล็ด และค่าปัจจัยรูปร่าง สามารถใช้เป็นตัวแปรสำคัญในการจำแนกสายพันธุ์ถั่วพิสตาชิโอได้อย่างมีประสิทธิภาพ เมื่อใช้เทคนิคการเรียนรู้ของเครื่อง จะสามารถเพิ่มความแม่นยำในการจำแนกได้มากกว่าวิธีการแบบดั้งเดิม

งานวิจัยนี้มุ่งเน้นการจำแนกสายพันธุ์ของถั่วพิสตาชิโอ ใช้เทคนิคการเรียนรู้ของเครื่อง เพื่อจำแนกสายพันธุ์ของถั่วพิสตาชิโอจำนวน 2 สายพันธุ์ ได้แก่ เคียร์มีซีและเซียร์ต โดยอาศัยลักษณะทางกายภาพของเมล็ดเป็นตัวแปรในการจำแนก ซึ่งประกอบด้วยตัวแปรอิสระจำนวน 16 ตัวแปร และตัวแปรตาม 1 ตัวแปร การนำเทคนิคการเรียนรู้ของเครื่องมาใช้ในการวิจัยนี้ มีวัตถุประสงค์เพื่อพัฒนาเทคนิคที่สามารถจำแนกสายพันธุ์ถั่วพิสตาชิโอได้อย่างรวดเร็วและมีประสิทธิภาพ ทั้งในด้านความแม่นยำและการลดข้อผิดพลาดในการจำแนก โดยเทคนิคการเรียนรู้ของเครื่องสามารถเรียนรู้รูปแบบเชิงซับซ้อนจากข้อมูลจำนวนมากและปรับตัวได้อัตโนมัติ ซึ่งช่วยให้การจำแนกสายพันธุ์มีความถูกต้องสูงกว่าวิธีการแบบดั้งเดิม

วัตถุประสงค์ของโครงการวิจัย

1. ศึกษาการจำแนกสายพันธุ์ถั่วพิสตาชิโอ ด้วยเทคนิคการจำแนก 4 เทคนิค ได้แก่ เพื่อบ้านใกล้ที่สุด ซัพพอร์ตเวกเตอร์แมชชีน ต้นไม้ป่าสุ่มและเอ็กซ์ตริมเกรเดียนต์ บูลสต์
2. เปรียบเทียบประสิทธิภาพของเทคนิคในการจำแนกสายพันธุ์ถั่วพิสตาชิโอ
3. เพื่อระบุปัจจัยที่มีอิทธิพลต่อการจำแนกสายพันธุ์ถั่วพิสตาชิโอมากที่สุด ด้วยวิธีการพิจารณาของ Gini และการลดลงของความแม่นยำ

สมมติฐาน

เทคนิคเพื่อบ้านใกล้ที่สุด ซัพพอร์ตเวกเตอร์แมชชีน ต้นไม้ป่าสุ่มและเอ็กซ์ตริมเกรเดียนต์ บูลสต์ มีประสิทธิภาพในการจำแนกสายพันธุ์ถั่วพิสตาชิโอที่แตกต่างกัน

ประโยชน์ที่คาดว่าจะได้รับ

1. สามารถนำเทคนิคการเรียนรู้ของเครื่องไปประยุกต์ใช้ในการจำแนกสายพันธุ์ถั่วพิสตาชิโอ
2. เพื่อเป็นแนวทางการประยุกต์ใช้เทคนิคในการคัดแยกสายพันธุ์ถั่วพิสตาชิโอสำหรับการผลิตหรือการวิจัยในภาคอุตสาหกรรมอาหารในอนาคต

วิธีการ

การวิจัยในครั้งนี้ เป็นการศึกษาการจำแนกสายพันธุ์ถั่วพิสตาชิโอ มีขั้นตอนในการดำเนินงานวิจัยดังนี้

ขั้นที่ 1 ศึกษาและรวบรวมข้อมูลที่เกี่ยวข้อง ซึ่งเป็นข้อมูลจากเว็บไซต์ของมูรด์ เคอคลือ จำนวน 2,148 ชุด โดยตัวแปรที่ใช้ในการศึกษานี้มีทั้งสิ้น 17 ตัวแปร จำแนกเป็น ตัวแปรอิสระ จำนวน 16 ตัวแปร ได้แก่ ค่าขนาดพื้นที่ของเมล็ด ค่าความยาวเส้นรอบวงของเมล็ด ความยาวแกนหลักของเมล็ด ความยาวแกนรองของเมล็ด อัตราส่วนระหว่างแกนหลักและแกนรองแสดงรูปร่างวงรี พื้นที่ของรูปนูนที่ครอบเมล็ด เส้นผ่านศูนย์กลางของวงกลมที่มีพื้นที่เท่ากับเมล็ด สัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของกรอบสี่เหลี่ยม สัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของรูปนูน ความกลมของเมล็ด อัตราส่วนระหว่างความยาวแกนหลักต่อแกนรอง ปัจจัยรูปร่าง1 ปัจจัยรูปร่าง2 ปัจจัยรูปร่าง3 ปัจจัยรูปร่าง 4ตัวแปรตามจำนวน 1 ตัวแปร คือ สายพันธุ์ถั่วพิสตาชิโอ แบ่งออกเป็น 2 สายพันธุ์ ได้แก่ เคียร์มีซี (Kirmizi) และ เซียร์ต (Siirt)

ตารางที่ 1 แสดงตัวแปรและประเภทของตัวแปร (List of Variables and Their Types)

ชื่อตัวแปร (Variable)	คำอธิบาย (Description)	ประเภทข้อมูล (Type)	ลักษณะตัวแปร (Qualitative/Quantitative)
Class	สายพันธุ์ถั่วพิสตาชิโอ (เคียร์มีซี และเซียร์ต)	Categorical	Qualitative
Area	ค่าขนาดพื้นที่ของเมล็ด	Numeric	Quantitative
Perimeter	ค่าความยาวเส้นรอบวงของเมล็ด	Numeric	Quantitative
Major_Axis_Length	ความยาวแกนหลักของเมล็ด	Numeric	Quantitative
Minor_Axis_Length	ความยาวแกนรองของเมล็ด	Numeric	Quantitative
Eccentricity	อัตราส่วนระหว่างแกนหลักและแกนรองแสดงรูปร่างวงรี	Numeric	Quantitative
Convex_Area	พื้นที่ของรูปนูนที่ครอบเมล็ด	Numeric	Quantitative
Equivalent_diameter	เส้นผ่านศูนย์กลางของวงกลมที่มีพื้นที่เท่ากับเมล็ด	Numeric	Quantitative
Extent	สัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของกรอบสี่เหลี่ยม	Numeric	Quantitative
Solidity	สัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของรูปนูน	Numeric	Quantitative
Roundness	ความกลมของเมล็ด	Numeric	Quantitative
Aspect_Ratio	อัตราส่วนระหว่างความยาวแกนหลักต่อแกนรอง	Numeric	Quantitative
Compactness	ค่าที่แสดงถึงความหนาแน่นของเมล็ด	Numeric	Quantitative
Shape_Factor1	ปัจจัยรูปร่าง 1 (มาจากสมการที่คำนวณจากขนาดและรอบรูป)	Numeric	Quantitative
Shape_Factor2	ปัจจัยรูปร่าง 2	Numeric	Quantitative
Shape_Factor3	ปัจจัยรูปร่าง 3	Numeric	Quantitative

Shape_Factor4	ปัจจัยรูปร่าง 4	Numeric	Quantitative
---------------	-----------------	---------	--------------

ขั้นที่ 2 เตรียมข้อมูลสำหรับนำไปวิเคราะห์ ผู้วิจัยทำการคัดเลือกข้อมูลที่จะนำไปใช้ในการวิเคราะห์แล้วนำข้อมูลที่ได้ไปตรวจสอบข้อมูล โดยการตัดข้อมูลที่ผิดปกติ และข้อมูลที่มีค่าสูญหาย ผู้วิจัยทำการวิเคราะห์ข้อมูลเบื้องต้นโดยใช้ ค่าต่ำสุด ค่าสูงสุด ค่าเฉลี่ย และ ส่วนเบี่ยงเบนมาตรฐาน

ขั้นที่ 3 การประมวลผลแต่ละเทคนิคการจำแนกสายพันธุ์ถั่วพิสตาชิโอด้วยโปรแกรม R โดยเทคนิคการเรียนรู้ของเครื่องจำนวน 4 เทคนิค ได้แก่ เพื่อนบ้านใกล้ที่สุด ขั้วพอร์ตเวกเตอร์แมชชีน ต้นไม้ป่าสุ่มและเอ็กซ์ตริมเกรเดียนต์บูสตั๊น ชุดข้อมูลฝึก (Training Set) ร้อยละ 80 ของข้อมูลทั้งหมด จำนวน 1,718 ตัวอย่าง และ ชุดข้อมูลทดสอบ (Testing Set) ร้อยละ 20 ของข้อมูลทั้งหมด จำนวน 430 ตัวอย่าง การแบ่งข้อมูลดังกล่าวเป็นแบบการสุ่มแบบแบ่งชั้น (Stratified Sampling) เพื่อคงสัดส่วนของแต่ละคลาสให้เท่ากันระหว่างชุดฝึกและชุดทดสอบ

เทคนิคเพื่อนบ้านใกล้ที่สุด (K-Nearest Neighbors) K-NN

หลักการของเทคนิคนี้คือ การจำแนกประเภทของข้อมูลโดยพิจารณาจากข้อมูลในชุดตัวอย่างฝึกที่มีคุณสมบัติใกล้เคียงที่สุดกับข้อมูลใหม่จำนวน K ตัว (นิซารีย์ ศรีบุญจันดี, 2566) เมื่อมีข้อมูลใหม่เข้ามา โมเดลจะคำนวณหาระยะทางระหว่างข้อมูลใหม่กับข้อมูลทุกตัวในชุดฝึก แล้วเลือกข้อมูล K ตัวที่มีระยะทางสั้นที่สุด (ใกล้ที่สุด) มาใช้ในการตัดสินผลการจำแนก โดยใช้หลัก เสียงข้างมาก (Majority Vote) เพื่อระบุว่าข้อมูลใหม่นั้นควรถูกจัดให้อยู่ในคลาสใด การวัดระยะทางที่นิยมใช้ในอัลกอริทึมเพื่อนบ้านใกล้ที่สุด คือระยะทางแบบ Euclidean distance ซึ่งมีหลักการว่า หากวัตถุสองตัวอยู่ห่างกันมาก แสดงว่าวัตถุนั้นมีความคล้ายกันน้อย แต่ถ้าอยู่ใกล้กันมาก แสดงว่ามีความคล้ายคลึงกันสูง อัลกอริทึมนี้จึงทำการจำแนกประเภทของข้อมูลโดยอาศัยแนวคิดของ “ความใกล้ชิด” ระหว่างข้อมูลใหม่และข้อมูลตัวอย่างในชุดฝึก เทคนิคเพื่อนบ้านใกล้ที่สุด จัดอยู่ในกลุ่มของการเรียนรู้แบบเฉื่อย (Lazy Learning) เนื่องจากไม่ได้สร้างเทคนิคล่วงหน้า แต่จะเก็บข้อมูลฝึกทั้งหมดไว้ และทำการคำนวณเมื่อมีข้อมูลใหม่เข้ามาเท่านั้น กล่าวคือ เมื่อมีข้อมูลใหม่ ระบบจะนำข้อมูลนั้นมาเปรียบเทียบกับข้อมูลฝึกทั้งหมด เพื่อหากลุ่มเพื่อนบ้านที่ใกล้เคียงที่สุด จากนั้นตัดสินผลจำแนกตามคลาสของเพื่อนบ้านส่วนใหญ่ ทำให้เทคนิคนี้มีข้อดีคือ ความเรียบง่าย และสามารถปรับใช้ได้กับข้อมูลที่มีหลายมิติ โดยไม่ต้องฝึกโมเดลซับซ้อนล่วงหน้า

จากนั้นทำการปรับแต่งค่าพารามิเตอร์ระดับสูง (Hyperparameter Optimization) ภายในขั้นตอนการฝึกแบบจำลอง ได้ใช้วิธีการตรวจสอบความถูกต้องแบบ 10 ส่วน (10-fold Cross Validation) บนชุดข้อมูลฝึกเท่านั้น เพื่อให้โมเดลสามารถหาค่าพารามิเตอร์ที่เหมาะสมที่สุดก่อนนำไปประเมินกับชุดข้อมูลทดสอบจริง ซึ่งเป็นวิธีมาตรฐานที่ช่วยลดความเอนเอียงจากการแบ่งข้อมูลฝึกและทดสอบ การปรับแต่งพารามิเตอร์ของเพื่อนบ้านใกล้ที่สุด ประกอบด้วย 3 ส่วนหลัก ได้แก่

1. **kmax** คือ จำนวนเพื่อนบ้านที่ใช้ในการพิจารณาในการจำแนก โดยในการทดลองได้กำหนดค่าช่วงตั้งแต่ 1 ถึง 30 เพื่อค้นหาค่าที่ให้ ความแม่นยำสูงสุด
2. **distance** คือ วิธีการคำนวณระยะทางระหว่างข้อมูล ซึ่งได้ทดสอบทั้งแบบ Manhattan และ Euclidean
3. **kernel** คือ รูปแบบการถ่วงน้ำหนักของเพื่อนบ้าน โดยได้ทดสอบทั้งแบบ rectangular, triangular และ gaussian

การปรับแต่งค่าพารามิเตอร์ทั้งสามนี้ทำให้เทคนิคเพื่อนบ้านใกล้ที่สุด สามารถเรียนรู้ลักษณะของข้อมูลได้ดีขึ้น ลดการเกิดปัญหาการเรียนรู้มากเกินไปและให้ค่าความแม่นยำสูงขึ้นเมื่อเทียบกับการใช้ค่าพารามิเตอร์เริ่มต้น (Default)

เทคนิคขั้วพอร์ตเวกเตอร์แมชชีน (Support Vector Machine) SVM

เป็นการเรียนรู้ของเครื่องประเภทแบบการเรียนรู้โดยอาศัยตัวอย่างประเภทหนึ่ง ซึ่งมีความสามารถในการจัดหมวดหมู่ และการทำนาย (Regression) โดยเอสวีเอ็มมีพื้นฐานจะมีการคำนวณแบบเชิงเส้น (Linear) ซึ่งจัดอยู่ในประเภทมุ่งหาผลลัพธ์ที่ดีที่สุดของการเรียนรู้ (Discriminative Training) บนการเรียนรู้จากสถิติของข้อมูลซึ่งทำงานโดยการหาค่าระยะขอบที่มากที่สุด (Maximum Margin) ของระนาบตัดสินใจ (Decision Hyperplane) (อังศุมลีย์ สุทธภักติ, 2554) ในการแบ่งแยกกลุ่มข้อมูลที่ใช้ฝึกฝนออกจากกัน วิธีการนี้มีชื่อเรียกอีกชื่อหนึ่งว่า จัดหมวดหมู่โดยค่าระยะขอบที่มากที่สุด (Maximum Margin Classifier)

หลักการทำงานของเอสวีเอ็มข้อมูลจะถูกเขียนในรูปสมาชิกคู่อันดับดังนี้

$$D = \{(x_1, c_1), (x_2, c_2), \dots, (x_n, c_n)\}$$
 (1)

เมื่อ C_i มีค่าเป็น 1 หรือ -1 ซึ่งกำหนดให้เป็นข้อมูลแบ่งกลุ่มของข้อมูล x_i ที่มีค่า C_i เป็น 1 และ x_i ที่มีค่า C_i เป็น -1 โดยที่แต่ละ x_i เป็นค่าข้อมูลมิติของเวกเตอร์จริง เมื่อกำหนดให้ข้อมูลนี้เป็น ข้อมูล สำหรับฝึกฝน ซึ่งหมายความว่า การแบ่งกลุ่มของข้อมูลมีความถูกต้อง ดังนั้นเส้นแบ่งกลุ่ม ข้อมูลที่ ถูกสร้างขึ้นซึ่งเป็นสมการเส้นตรงทั่วไปคือ $y = mx + b$ โดยในที่นี้จะแทน m ด้วย w^T เพื่อกำหนดเป็น สมการ

$$w^T x + b = 0 \quad (2)$$

เมื่อ w^T คือ เวกเตอร์ตั้งฉากของค่าความชัน m ของเส้นแบ่ง

b คือ ค่าคงที่ที่ได้จากค่าของแกน y ของแต่ละข้อมูล x

เส้นแบ่งกลุ่มที่ดีที่สุดคือเส้นแบ่งกลุ่มที่ทำให้มีระยะขอบ (Margin) มากที่สุด ของเส้นคู่ขนานที่ขยายออกจากเส้นแบ่งไปสัมผัสจุด ข้อมูลของทั้งสองกลุ่มที่ใกล้ที่สุด หรือกล่าวได้ว่าเป็นเส้นแบ่งที่มีระยะขอบกว้างที่สุด เรียกจุดข้อมูลอย่างน้อยหนึ่ง จุดจากทั้งสองกลุ่มที่สัมผัส กับเส้นขนานที่ขยายออกได้มากที่สุดว่า ซัพพอร์ตเวกเตอร์ โดยค่าของเส้นขอบทั้งสองที่ใช้แบ่งกลุ่มข้อมูลเป็นสองกลุ่มคำนวณได้จากสมการ

$$w^T x + b = 1 \quad (3)$$

$$w^T x + b = -1 \quad (4)$$

เมื่อข้อมูลที่ใช้ฝึกฝนเป็นข้อมูลที่สามารถแบ่งกลุ่มได้ด้วยเส้นตรงใด ๆ ระยะที่กว้างที่สุด ของไฮเปอร์เพลน (Hyper plane) ทั้งสอง ที่ขยายออกไปจนกว่าจะพบจุดข้อมูลของทั้งสองกลุ่มคือ $\frac{2}{|w|}$ โดยค่า $|w|$ มีค่าน้อยที่สุดค่าข้อมูลแต่ละ x_i จุดจำแนกอยู่ในกลุ่มใดสามารถ พิจารณาได้จาก เงื่อนไขดังนี้ ถ้า $w^T x + b \geq 1$ แสดงว่า x_i เป็นกลุ่มที่ 1 และถ้า $w^T x + b \leq -1$ แสดงว่า x_i เป็น กลุ่มที่ 2 ใน การคัดแยกจุดข้อมูลใด ๆ ที่นำมาฝึกฝนเพื่อกรองว่าเป็นกลุ่ม 1 สามารถตรวจสอบ ได้จากสมการ

$$c_i(w \cdot x_i - b) \geq 1 \text{ เมื่อ } 1 \leq i \leq n \quad (5)$$

ดังนั้นสามารถเขียนเป็นรูปสั้นเพื่อหาระยะขอบที่น้อยที่สุด โดยที่สามารถคำนวณการ แบ่งกลุ่มได้ดังสมการ

$$\text{Minimize}_{w,b} |w| \text{ โดยตรวจสอบ } c_i(w \cdot x_i - b) \geq 1 \text{ เมื่อ } 1 \leq i \leq n \quad (6)$$

ของต้นไม้นี้แต่ละต้นมาร่วมกันตัดสินใจ จากนั้นจึงเลือกผลลัพธ์การจำแนกที่ได้รับการโหวตมากที่สุด

ในการสร้างเทคนิคซัพพอร์ตเวกเตอร์แมชชีน เพื่อจำแนกสายพันธุ์ของถั่วพิสตาชิโอ ได้มีการปรับแต่งค่าพารามิเตอร์ระดับสูง เพื่อเพิ่มความสามารถในการจำแนกข้อมูลให้มีความแม่นยำสูงสุด โดยดำเนินการปรับแต่งภายใต้ กระบวนการตรวจสอบไขว้แบบ 10 ส่วน ซึ่งเป็นวิธีมาตรฐานที่ช่วยลดความเอนเอียงจากการแบ่งข้อมูลฝึกและทดสอบ ได้แก่

สำหรับ SVM-Linear ได้ทำการปรับค่าพารามิเตอร์ C (Cost parameter) ซึ่งเป็นค่าที่ควบคุมความซับซ้อนของเส้นขอบเขต การจำแนก (Decision Boundary) โดยค่านี้มีบทบาทสำคัญในการกำหนดระดับความเข้มงวดของเทคนิคต่อข้อมูลที่จำแนกผิด หากกำหนดค่า C มีค่าน้อย โมเดลจะยอมให้ข้อมูลบางส่วนจำแนกผิดเพื่อให้ได้เส้นแบ่งที่กว้างขึ้น ซึ่งอาจนำไปสู่การเรียนรู้ต่ำเกินไป (Underfitting) ในขณะที่ค่าที่ สูงเกินไปอาจทำให้แบบจำลองจำแนกข้อมูลเฉพาะในชุดฝึกและเกิดปัญหาการเรียนรู้มากเกินไปได้ จากการปรับแต่ง ค่าพารามิเตอร์พบว่า ที่เหมาะสม ที่สุดคือ $C = 8 (2^3)$ ซึ่งเป็นค่าที่ช่วยให้โมเดลสามารถสร้างเส้นขอบจำแนกได้อย่างสมดุลมีความยืดหยุ่น เพียงพอ และมีความแม่นยำสูงสุดสำหรับข้อมูลชุดนี้

สำหรับ SVM-RBF (Radial Basis Function Kernel) ได้มีการปรับแต่งค่าพารามิเตอร์หลักสองค่า ได้แก่ C (Cost parameter) และ σ (Sigma) ซึ่ง σ เป็นค่าที่กำหนดความโค้งของฟังก์ชัน Kernel RBF ในการแปลงข้อมูลไปยังมิติที่สูงขึ้นเพื่อแยกคลาสที่ไม่สามารถจำแนกเชิงเส้นได้ หากค่าของ σ สูงเกินไป เส้นขอบจำแนกจะเรียบเกินไปและอาจไม่สามารถแยกข้อมูลได้ดี ในขณะที่ค่าที่ต่ำเกินไปจะทำให้เส้นขอบซับซ้อนและมีแนวโน้มเกิดปัญหาการเรียนรู้มากเกินไป จากการปรับแต่งพบว่าค่าที่ให้ผลดีที่สุดคือ $C = 32 (2^5)$ และ $\sigma = 0.0156 (2^{-6})$ ซึ่งช่วยให้แบบจำลอง สามารถสร้างเส้นขอบที่โค้งและยืดหยุ่นได้อย่างเหมาะสม รองรับการจำแนกข้อมูลที่มีรูปแบบความสัมพันธ์ไม่เป็นเชิงเส้นได้ดี และให้ผล การทำนายที่มีความแม่นยำสูงที่สุดในกลุ่ม SVM

ในส่วนของ SVM-Polynomial ได้มีการปรับแต่งค่าพารามิเตอร์ degree, scale (หรือ γ - Gamma) และ C (Cost parameter) เพื่อเพิ่มความสามารถในการสร้างเส้นขอบที่ซับซ้อนมากขึ้น โดยพารามิเตอร์ degree ควบคุมลำดับของสมการพหุนามที่ใช้ในการแปลงข้อมูล scale หรือ γ ควบคุมความโค้งของเส้นขอบ และ C ใช้ควบคุมระดับความเข้มงวดของการจำแนกข้อมูล จากการปรับแต่งพบว่าค่าที่ให้ผลดีที่สุดคือ degree = 3, $\gamma = 0.0625 (2^{-4})$ และ $C = 8 (2^3)$ ซึ่งค่าดังกล่าวช่วยให้แบบจำลองสามารถสร้างเส้นขอบการจำแนกที่มีความโค้งและซับซ้อนเพียงพอ เหมาะสมกับข้อมูลที่มีลักษณะการกระจายไม่เป็นเชิงเส้น ส่งผลให้แบบจำลองสามารถจำแนกสายพันธุ์ของถั่วพิสตาชิโอได้อย่างแม่นยำและมีเสถียรภาพ

เทคนิคต้นไม้ป่าสุ่ม (Random forest)

เป็นเทคนิคการเรียนรู้แบบมีผู้สอนแบบหนึ่งที่ใช้ทำงานง่าย ถูกพัฒนามาจากเทคนิคต้นไม้ตัดสินใจ (Decision tree) สำหรับงานด้านการจำแนกกลุ่มข้อมูล ต้นไม้ป่าสุ่มเกิดจากการรวมกลุ่มกันของโครงสร้างต้นไม้ตัดสินใจ ค่าความคลาดเคลื่อนโดยรวมของต้นไม้ป่าสุ่มจะถูกเปลี่ยนให้เป็นค่าลิมิต ทำให้จำนวนของต้นไม้ในป่าเพิ่มขึ้น ค่าความคลาดเคลื่อนโดยรวมจะขึ้นกับความมั่นคงของต้นไม้แต่ละต้น โดยจะใช้วิธีการสุ่มเลือก คุณสมบัติเพื่อการแบ่งแยกโหนด ทำให้ค่าความผิดพลาดลดลง หลักการที่สำคัญของเทคนิคต้นไม้ป่าสุ่ม คือการสร้างต้นไม้ตัดสินใจอย่างง่ายจำนวนมากใน ขั้นตอนการฝึกฝน และใช้วิธีการทำการหลักการตัดสินใจแบบเสียงข้างมากหรือการลงคะแนนเสียงข้างมากช่วยในการ ตัดสินใจผลการจำแนกกลุ่มของข้อมูล (อดิเรก บัณฑิต, 2566)

โดยทำการปรับแต่งค่าพารามิเตอร์ระดับสูง ของเพื่อเทคนิคต้นไม้ป่าสุ่ม เพื่อเพิ่มประสิทธิภาพของการจำแนกสายพันธุ์ของถั่วพิสตาชิโอให้มีความแม่นยำมากยิ่งขึ้น โดยใช้กระบวนการตรวจสอบแบบไขว้ 10 ส่วน ภายใต้การควบคุมการสุ่มตัวอย่าง (set.seed) เพื่อให้ผลลัพธ์มีความคงที่และสามารถทำซ้ำได้ การปรับแต่งพารามิเตอร์ของแบบจำลองนี้ประกอบด้วยพารามิเตอร์หลัก 3 ตัว ได้แก่

1. ntree คือ จำนวนต้นไม้ (Number of Trees) ที่ใช้ในการสร้างแบบจำลอง โดยในงานวิจัยได้ทดสอบค่าที่ 100, 200 และ 300 เพื่อตรวจสอบว่าจำนวนต้นไม้เท่าใดให้ผลลัพธ์ที่มีความถูกต้องสูงสุด
2. mtry คือ จำนวนตัวแปรที่ถูกสุ่มเลือกในแต่ละการแตกโหนดของต้นไม้ (Number of Variables per Split) โดยได้ทำการทดสอบค่าที่ 2, 4, 8, 12 และ 16 ระหว่างความซับซ้อนและความแม่นยำ
3. Nodesize คือ ขนาดขั้นต่ำของข้อมูลในแต่ละใบสุดท้ายของต้นไม้ (Minimum Node Size) ซึ่งส่งผลต่อระดับความละเอียดในการจำแนกข้อมูล ได้ทำการทดสอบค่าที่ 1, 3, 5 และ 10

ในเทคนิคต้นไม้ป่าสุ่ม งานวิจัยนี้ใช้นิยามของ Gini Impurity เป็นตัววัดความไม่บริสุทธิ์ (impurity) ของข้อมูลภายในโหนด โดย Gini Impurity วัดโอกาสที่ถ้าเลือกตัวอย่างหนึ่งมาอย่างสุ่มและจัดหมวดหมู่โดยอาศัยการแจกแจงคลาส (Class Distribution) ในโหนดนั้น จะถูกจัดผิดคลาสได้ สูตรของ Gini Impurity เขียนได้เป็น

$$I_G(p) = 1 - \sum_{i=1}^J p_i^2 \quad (7)$$

โดยที่ p_i คือ สัดส่วนของข้อมูลในโหนดที่เป็นคลาส i , J คือจำนวนคลาสทั้งหมดในข้อมูล

ดังนั้น ค่า Gini ที่ลดลง (Mean Decrease Gini) จึงเป็นตัวบ่งชี้ความสำคัญของตัวแปรในการจำแนกข้อมูล หากตัวแปรใดทำให้ค่า Gini ลดลงได้มาก แสดงว่าตัวแปรนั้นมีอิทธิพลสูงต่อการจำแนกสายพันธุ์ถั่วพิสตาชิโอ ในเทคนิคต้นไม้ป่าสุ่ม

เทคนิคเอ็กซ์ตรีมเกรเดียนต์บูสติง (Extreme Gradient Boosting) XGBoost

เป็นเทคนิคการเรียนรู้ของเครื่องที่พัฒนามาจากอัลกอริทึมต้นไม้ความเร็วแบบไล่ระดับ (Gradient Boosted Tree) จัดอยู่ในกลุ่มวิธีการเอนเซมเบิล (ensemble learning method) โดยแบบจำลองได้เลือกใช้ต้นไม้ตัดสินใจ (Decision Tree) มาฝึกสอนต่อกันจำนวนหลายๆ ต้นเพื่อเรียนรู้จากค่าความผิดพลาด (โชติมา ดีพัฒน์, 2564) ของกระบวนการทำงานก่อนหน้านี้ ส่งผลต่อการพยากรณ์ที่ให้ค่าความแม่นยำมากขึ้น โดยแบบจำลองจะถูกหยุดการเรียนรู้เมื่อพบว่าการเรียนรู้ของต้นไม้ตัดสินใจต่อเนื่องจนมีความลึกมากเพียงพอจนไม่เหลือค่าความผิดพลาดจากต้นไม้ตัดสินใจต้นก่อนหน้านี้ให้เรียนรู้ ดัง สมการ

$$\hat{y}_i = \sum_{k=1}^k f_k(x_i) \quad (8)$$

โดยที่ $\hat{y}_i$ คือค่าพยากรณ์ของข้อมูลลำดับที่ i
 x_i คือ Feature Vector
 k คือ จำนวนต้นไม้การตัดสินใจ
 $f_k(x_i)$ คือค่าพยากรณ์ของลำดับที่ k

ในบทความนี้เราจะปรับแต่งแบบจำลองเอ็กซ์ตรีมเกรเดียนต์บูสต์ติ้ง ซึ่งเป็นเทคนิคแบบ Ensemble Learning ที่ใช้กระบวนการบูสต์ต้นไม้ตัดสินใจ (Decision Trees) หลายต้นแบบลำดับขั้น ได้มีการดำเนินการปรับค่าพารามิเตอร์ระดับสูง เพื่อให้โมเดลสามารถเรียนรู้ข้อมูลได้อย่างมีประสิทธิภาพสูงสุด โดยใช้วิธีการตรวจสอบไขว้แบบ 10 ส่วน เพื่อลดการเกิดปัญหาการเรียนรู้มากเกินไป และเพิ่มความเที่ยงตรงของผลลัพธ์ ในการปรับแต่งพารามิเตอร์ ประกอบด้วยพารามิเตอร์หลักดังต่อไปนี้

1. Nrounds เป็นจำนวนรอบของการสร้างต้นไม้ย่อย (Boosting Iterations) ซึ่งแต่ละรอบจะทำการเพิ่มต้นไม้ใหม่เพื่อแก้ไขข้อผิดพลาดจากรอบก่อนหน้านี้ โดยในงานนี้ได้ทำการทดสอบค่าที่ 100, 200 และ 300 และพบว่าค่าที่ให้ประสิทธิภาพดีที่สุดคือ **nrounds = 200** ซึ่งเป็นจำนวนรอบที่สมดุลระหว่างความแม่นยำและเวลาในการประมวลผล
2. Eta เป็นค่าที่ใช้ควบคุมอัตราการปรับน้ำหนักของแต่ละต้นไม้ เพื่อป้องกันไม่ให้เกิดการเรียนรู้เร็วเกินไปจนเกิด Overfitting โดยได้ทดสอบค่าที่ 0.01, 0.05, 0.1, 0.2 และ 0.3 และพบว่าค่าที่เหมาะสมที่สุดคือ **$\eta = 0.1$** ซึ่งช่วยให้แบบจำลองเรียนรู้ได้อย่างมีประสิทธิภาพและลดความแปรปรวนในผลลัพธ์
3. Max_depth เป็นค่าที่กำหนดระดับความซับซ้อนของแต่ละต้นไม้ หากตั้งค่าสูงเกินไปอาจทำให้โมเดลเกิด Overfitting ได้ โดยในงานนี้ได้ทดสอบค่าที่ 3, 5 และ 7 และพบว่าค่าที่เหมาะสมที่สุดคือ **max_depth = 5** ซึ่งให้ผลลัพธ์ที่มีความสมดุลระหว่างความซับซ้อนของแบบจำลองและความสามารถในการจำแนกข้อมูล
4. Gamma เป็นค่าที่กำหนดเกณฑ์ขั้นต่ำของการลดค่าฟังก์ชันสูญเสีย (Loss Function) ก่อนที่จะอนุญาตให้แตกโหนดใหม่ โดยในงานนี้ได้ทดสอบค่า 0 และ 1 และพบว่าค่าที่เหมาะสมคือ **$\gamma = 1$** ซึ่งช่วยควบคุมไม่ให้โมเดลแตกโหนดเกินความจำเป็น ทำให้แบบจำลองมีความเรียบง่ายและป้องกัน Overfitting ได้ดี
5. Min_child_weight พารามิเตอร์นี้ใช้ควบคุมไม่ให้เกิดการแบ่งข้อมูลย่อยมากเกินไป (Over-splitting) ซึ่งในงานนี้ได้ทดสอบค่าที่ 1 และ 3 และพบว่าค่าที่ให้ผลดีที่สุดคือ **min_child_weight = 3** ช่วยให้ต้นไม้มีความสมดุลและลดการเรียนรู้จาก noise ในข้อมูล
6. Subsample เป็นการสุ่มข้อมูลบางส่วนมาใช้ในการสร้างต้นไม้ในแต่ละรอบ เพื่อป้องกันไม่ให้โมเดลเรียนรู้จากข้อมูลเดิมซ้ำมากเกินไปและลด Overfitting โดยใช้ค่า **subsample = 0.8** ซึ่งเป็นค่าที่เหมาะสมในการรักษาสมดุลของการเรียนรู้
7. Colsample_bytree เป็นพารามิเตอร์ที่ควบคุมจำนวนตัวแปรที่สุ่มเลือกมาใช้ในการสร้างแต่ละต้นไม้เพื่อเพิ่มความหลากหลายของแบบจำลองและลดการพึ่งพาตัวแปรเดิมซ้ำ ในงานนี้ได้กำหนดค่า **colsample_bytree = 0.8** ซึ่งช่วยเพิ่มความทนทานของโมเดลต่อข้อมูลใหม่ (Generalization Capability)

ขั้นที่ 4 พิจารณาประสิทธิภาพของข้อมูล หลังจากสร้างแบบจำลองวิเคราะห์ข้อมูลแล้ว นำตัวแบบของแบบจำลองที่ได้มาทดสอบประสิทธิภาพของข้อมูล

$$\text{ค่าความแม่นยำ (Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN} \quad (9)$$

$$\text{ค่าการเรียกคืน (Recall)} = \frac{TP}{TP + FN} \quad (10)$$

$$\text{ค่าประสิทธิภาพโดยรวม (f - measure)} = \frac{2 \times \text{ค่าความแม่นยำ} \times \text{ค่าการเรียกคืน}}{\text{ค่าความแม่นยำ} + \text{ค่าการเรียกคืน}} \quad (11)$$

เมื่อ

TP แทน ผลบวกจริง (True Positive)

FP แทน ผลบวกปลอม (False Positive)

TN แทน ผลลบจริง (False Negative)

FN แทน ผลลบปลอม (False Negative)

โดยในการศึกษาครั้งนี้จะพิจารณาจากค่าความแม่นยำที่ใช้ในการจำแนกประเภทข้อมูล ที่ให้ค่าความแม่นยำสูงสุด แสดงว่ามีประสิทธิภาพมากที่สุด

ผลและอภิปราย

การเปรียบเทียบประสิทธิภาพของเทคนิคการจำแนกสายพันธุ์ถั่วพิสตาชิโอ โดยใช้เทคนิคการเรียนรู้ของเครื่องจำนวน 4 วิธี ได้แก่ เทคนิคเพื่อนบ้านที่ใกล้ที่สุด ชัฟฟอร์ตเวกเตอร์แมชชีน ต้นไม้ป่าสุ่มและเอ็กซ์ตริมเกรเดียนต์บูสติง เพื่อเปรียบเทียบค่าความแม่นยำ ค่าการเรียกคืนและค่าประสิทธิภาพโดยรวม ของแต่ละเทคนิคในการจำแนกสายพันธุ์ถั่ว เคียรีมีซี และ เชียร์ด

ตารางที่ 2 ผลการเปรียบเทียบประสิทธิภาพของเทคนิคการจำแนกสายพันธุ์ถั่วพิสตาชิโอ

เทคนิค	ค่าการเรียกคืน	ค่าประสิทธิภาพโดยรวม	ค่าความแม่นยำ
ต้นไม้ป่าสุ่ม	0.9106 *	0.8871 *	0.8671 *
ชัฟฟอร์ตเวกเตอร์แมชชีน	0.8943	0.8835	0.8648
เพื่อนบ้านที่ใกล้ที่สุด	0.8943	0.8800	0.8601
เอ็กซ์ตริมเกรเดียนต์บูสติง	0.8984	0.8787	0.8578

จากตารางที่ 2 พบว่า เทคนิคต้นไม้ป่าสุ่ม ให้ผลการจำแนกที่ดีที่สุด โดยมีค่าการเรียกคืนเท่ากับ 0.9106 ค่าประสิทธิภาพโดยรวมเท่ากับ 0.8871 และค่าความแม่นยำเท่ากับ 0.8671 แสดงให้เห็นถึงความสามารถของเทคนิคในการเรียนรู้ ความสัมพันธ์เชิงซับซ้อนของตัวแปรภายในข้อมูลได้อย่างมีประสิทธิภาพอีกทั้งยังสามารถจัดการกับความแปรปรวนของข้อมูลได้ดี


เทคนิคชัฟฟอร์ตเวกเตอร์แมชชีน มีผลลัพธ์รองลงมาโดยมีค่าการเรียกคืน 0.8943 ค่าประสิทธิภาพโดยรวม 0.8835 และค่าความแม่นยำ 0.8648 ซึ่งมีประสิทธิภาพใกล้เคียงกับเทคนิคต้นไม้ป่าสุ่ม แสดงให้เห็นถึงความสามารถของชัฟฟอร์ตเวกเตอร์ แมชชีน

ในการสร้างเส้นแบ่งขอบเขตที่เหมาะสมสำหรับการแยกกลุ่มข้อมูลที่มีความแตกต่างชัดเจนโดยเฉพาะอย่างยิ่งในกรณีที่ข้อมูลมีลักษณะเชิงเส้น (Linear Separation) และไม่มีสัญญาณรบกวนสูง

เทคนิคเพื่อนบ้านใกล้ที่สุด ให้ผลลัพธ์ที่อยู่ในระดับใกล้เคียงกับซัพพอร์ตเวกเตอร์แมชชีน โดยมีค่าการเรียกคืน 0.8943 ค่าประสิทธิภาพโดยรวม 0.8800 และค่าความแม่นยำ 0.8601 ซึ่งสะท้อนให้เห็นว่าการจำแนกโดยอาศัยระยะห่าง ระหว่างข้อมูลด้วยวิธี Euclidean Distance สามารถบ่งชี้ความคล้ายคลึงระหว่างตัวอย่างในแต่ละสายพันธุ์ได้อย่างมีประสิทธิภาพ

เทคนิคเอ็กซ์ตรีมเกรเดียนต์บูตติ้ง มีการเรียกคืน 0.898 ค่าประสิทธิภาพโดยรวม 0.8787 และค่าความแม่นยำ 0.8578 ซึ่งจัดอยู่ในระดับที่ดี แต่มีประสิทธิภาพต่ำกว่าเทคนิคต้นไม้ป่าสุ่มเล็กน้อย เนื่องจากโครงสร้างของเอ็กซ์ตรีมเกรเดียนต์บูตติ้ง เป็นแบบ Boosting ที่สร้างต้นไม้ตัดสินใจแบบลำดับขั้น (Sequential Trees) โดยแต่ละต้นไม้จะเรียนรู้จากข้อผิดพลาดของต้นไม้ ก่อนหน้า จึงมักให้ผลลัพธ์ที่โดดเด่นในข้อมูลที่มีความซับซ้อนสูงหรือ มีความไม่สมดุลของสายพันธุ์ แต่สำหรับชุดข้อมูลพืชชาติโอ ที่มีการแยกสายพันธุ์ชัดเจนและไม่มีความไม่สมดุลสูงต้นไม้ป่าสุ่ม ซึ่งใช้การสุ่มตัวแปรและต้นไม้จำนวนมากในการสร้างเทคนิคจึงสามารถให้ผลลัพธ์ที่ดีกว่าในกรณีนี้

ภาพที่ 1 แสดงค่าความสำคัญของตัวแปร จากเทคนิคต้นไม้ป่าสุ่ม สำหรับการจำแนกสายพันธุ์พืชชาติโอ



จาก ภาพที่ 1 แสดงผลการวิเคราะห์ความสำคัญของตัวแปร (Variable Importance Plot) ของแบบจำลองต้นไม้ป่าสุ่ม ซึ่งใช้ตัวชี้วัดหลักสองค่าในการประเมินความสำคัญของตัวแปร ได้แก่ ค่าการลดลงของความแม่นยำ (Mean Decrease Accuracy) และค่าการลดลงของ Gini (Mean Decrease Gini) โดยค่าทั้งสองนี้สะท้อนถึงระดับของอิทธิพลที่แต่ละตัวแปรมีต่อความสามารถของแบบจำลองในการจำแนกประเภทข้อมูล กล่าวคือ ค่าการลดลงของความแม่นยำ ใช้บ่งบอกว่าหากนำตัวแปรนั้นออกจากแบบจำลอง ความแม่นยำโดยรวมจะลดลงมากเพียงใด ส่วนค่าการลดลงของ Gini แสดงระดับการมีส่วนร่วมของตัวแปรในการแยกข้อมูลออกเป็นกลุ่มในกระบวนการสร้างต้นไม้ตัดสินใจ

จากผลการวิเคราะห์พบว่า ตัวแปรที่มีความสำคัญต่อแบบจำลองมากที่สุด ได้แก่ ปัจจัยรูปร่าง 1 ปัจจัยรูปร่าง 3 ปัจจัยรูปร่าง 4 ความยาวแกนรองของเมล็ดและค่าความหนาแน่นของเมล็ด ซึ่งทั้งหมดนี้มีค่าการลดลงของความแม่นยำและค่าการลดลงของ Gini ในระดับสูงกว่าตัวแปรอื่นอย่างชัดเจน แสดงให้เห็นว่าตัวแปรเหล่านี้มีอิทธิพลอย่างมีนัยสำคัญต่อความสามารถของเทคนิคในการจำแนกสายพันธุ์พืชชาติโอ ได้อย่างถูกต้อง ตัวแปรที่มีความสำคัญน้อยที่สุด ได้แก่ ปัจจัยรูปร่าง 2 อัตราส่วนระหว่างแกนหลักและแกนรองที่แสดงรูปร่างวงรี และสัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของกรอบสี่เหลี่ยม ซึ่งตัวแปรเหล่านี้มีค่าการลดลงของความแม่นยำและค่า Gini อยู่ในระดับต่ำ แสดงว่ามีอิทธิพลต่อผลการจำแนกในระดับจำกัด

ผลการวิเคราะห์ดังกล่าวชี้ให้เห็นว่า เทคนิคต้นไม้ป่าสุ่ม สามารถระบุคุณลักษณะที่สำคัญทางกายภาพของเมล็ดถั่วได้อย่างมีประสิทธิภาพ โดยเฉพาะกลุ่มตัวแปรที่เกี่ยวข้องกับลักษณะรูปร่างและขนาดของเมล็ด เช่น ความยาวแกนรองและค่าปัจจัยรูปร่าง ซึ่งเป็นคุณลักษณะที่ช่วยแยกความแตกต่างระหว่างสายพันธุ์ เคียร์มีซี และ เซียร์ต ได้อย่างชัดเจนและแม่นยำการระบุคุณลักษณะสำคัญเหล่านี้ ไม่เพียงช่วยเพิ่มความเข้าใจเชิงลึกเกี่ยวกับความแตกต่างทางลักษณะภายนอกของถั่วแต่ละสายพันธุ์เท่านั้น แต่ยังสามารถนำไปใช้เป็นแนวทางในการจำแนกสายพันธุ์อัตโนมัติด้วยเทคนิคการเรียนรู้ของเครื่องในงานวิจัยต่อไปได้อย่างมีประสิทธิภาพ

บทสรุป

การวิจัยครั้งนี้มีวัตถุประสงค์เพื่อวิเคราะห์และเปรียบเทียบประสิทธิภาพของแบบจำลองการเรียนรู้ของ ในการจำแนกประเภทของ ถั่วพิสตาชิโอ ซึ่งเป็นตัวแปรเป้าหมายแบ่งออกเป็น 2 สายพันธุ์ ได้แก่ เคียร์มีซี และ เซียร์ต โดยใช้ข้อมูลคุณลักษณะทางกายภาพของเมล็ดถั่ว จำนวน 16 ตัวแปร เช่น ค่าขนาดพื้นที่ของเมล็ด ค่าความยาวเส้นรอบวงของเมล็ด ความยาวแกนหลักของเมล็ด ความยาวแกนรองของเมล็ด อัตราส่วนระหว่างแกนหลักและแกนรอง แสดงรูปร่างวงรี พื้นที่ของรูปนูนที่ครอบเมล็ด เส้นผ่านศูนย์กลางของวงกลมที่มีพื้นที่เท่ากับเมล็ด สัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของกรอบสี่เหลี่ยม สัดส่วนระหว่างพื้นที่ของเมล็ดต่อพื้นที่ของรูปนูน ความกลมของเมล็ด อัตราส่วนระหว่างความยาวแกนหลักต่อแกนรอง ปัจจัยรูปร่าง 1 ปัจจัยรูปร่าง 2 ปัจจัยรูปร่าง 3 ปัจจัยรูปร่าง 4 สายพันธุ์ถั่วพิสตาชิโอ เป็นต้น ทั้งหมดอยู่ในรูปของข้อมูลเชิงปริมาณ ข้อมูลทั้งหมดถูกแบ่งออกเป็น 2 ส่วน คือชุดข้อมูลฝึกร้อยละ 80 ของข้อมูลทั้งหมด จำนวน 1,718 ตัวอย่าง และชุดข้อมูลทดสอบร้อยละ 20 ของข้อมูลทั้งหมด จำนวน 430 ตัวอย่าง และประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่อง 4 เทคนิค ได้แก่ เพื่อบ้านใกล้ที่สุด ซัพพอร์ตเวกเตอร์แมชชีน ต้นไม้ป่าสุ่ม ซึ่งการประเมินผลของเทคนิคจะพิจารณาจากค่าสูงสุดของค่าความแม่นยำ ค่าการเรียกคืน และ ค่าประสิทธิภาพโดยรวม โดยผลการศึกษาพบว่า เทคนิคต้นไม้ป่าสุ่ม มีประสิทธิภาพสูงที่สุดในการจำแนกสายพันธุ์ของ ถั่วพิสตาชิโอ โดยให้ค่าการเรียกคืนเท่ากับ 0.9106 ค่าประสิทธิภาพโดยรวมเท่ากับ 0.8871 ความแม่นยำเท่ากับ 0.8671 ซึ่งสูงที่สุดเมื่อเปรียบเทียบกับเทคนิคอื่น แสดงให้เห็นถึงความสามารถของเทคนิคในการจำแนกสายพันธุ์ถั่วพิสตาชิโอได้อย่างแม่นยำสูง ตัวแบบที่ได้จากเทคนิคต้นไม้ป่าสุ่มสามารถนำมาใช้เป็นแนวทางสำหรับการจำแนกสายพันธุ์ถั่วพิสตาชิโอ ในภาคอุตสาหกรรมอาหารในอนาคต

เอกสารอ้างอิง

- กัลยา บุญหล้า,วรุฒิ มหาโพธิ์. (2565). การจำแนกคุณภาพน้ำในประเทศไทยโดยใช้เทคนิคเหมืองข้อมูล. วารสารวิทยาศาสตร์และเทคโนโลยี, 29-30. สืบค้นเมื่อ 16 มกราคม 2568, จาก https://scholar.google.co.th/citations?view_op=view_citation&hl=th&user=nWTh8RUAAAAJ&citation_for_view=nWTh8RUAAAAJ:ufrVoPGSRksC
- โชติมา ดีพัฒน์. (2564). การพัฒนาแบบจำลองด้วยเทคนิคการเรียนรู้ของเครื่องเพื่อพยากรณ์พื้นที่ในประเทศไทยที่มีความเสี่ยงได้รับผลกระทบจากการเกิดดินโคลนถล่ม. วิทยานิพนธ์ปริญญาโทมหาบัณฑิต สาขาวิชาวิศวกรรมข้อมูลขนาดใหญ่ มหาวิทยาลัยธุรกิจบัณฑิตย์, 12-18. สืบค้นเมื่อ 25 กุมภาพันธ์ 2568, จาก <https://libdoc.dpu.ac.th/thesis/Chotima.Deep.pdf>
- ณิชากร ศรีบุญจันดี. (2566). การจำแนกสายพันธุ์ถั่วพิสตาชิโอโดยใช้เทคนิคการเรียนรู้เชิงลึก. วิทยานิพนธ์ปริญญาโทมหาบัณฑิต, มหาวิทยาลัยศรีนครินทรวิโรฒ. สืบค้นเมื่อ 16 มกราคม 2568, จาก <http://ir-ithesis.swu.ac.th/dspace/bitstream/123456789/2759/1/gs651160180.pdf>
- มูลนิธิหัวใจแห่งประเทศไทยในพระบรมราชูปถัมภ์. (2021). ถั่วพิสตาชิโอ (Pistachio). สืบค้นเมื่อ 16 มกราคม 2568, จาก <https://www.thaiheartfound.org/Article/Detail/140110>
- อดิเรก บัณฑิต. (2566). แบบจำลองการพยากรณ์การผลิตพลังงานแสงอาทิตย์บนทุ่นลอยน้ำโดยอาศัยวิธีการหน่วยความจำระยะสั้นแบบยาวและเอ็กซ์ตรึมเกรเดียนต์บูตัสติง (วิทยานิพนธ์ปริญญาโทมหาบัณฑิต). มหาวิทยาลัยสุโขทัยธรรมาธิราช. 18-19. สืบค้นเมื่อ 10 มีนาคม 2568, จาก <https://ir.stou.ac.th/bitstream/123456789/13031/1/2659600445.pdf>
- อังศุมาลี สุทธิภักดี. (2554) การเปรียบเทียบประสิทธิภาพของการจำแนกหมวดหมู่ของข้อคิดเห็นในแบบสอบถามปลายเปิด โดยวิธีเอนีฟเบย์และซัพพอร์ตเวกเตอร์แมชชีน. วิทยาลัยราชพฤกษ์-นนทบุรี. สืบค้นเมื่อ 25 กุมภาพันธ์ 2568, จาก https://doi.nrct.go.th/ListDoi/listDetail?Resolve_DOI=10.14458/RPU.res.2011.9
- Food and Agriculture Organization of the United Nations. (2023). FAOSTAT Database.. Retrieved February 22, 2025, from <https://www.fao.org/faostat/en/#data>

Koklu, M. (2022). Pistachio dataset. Murat Koklu Datasets. Retrieved January 16, 2025, from <https://www.muratkoklu.com/datasets/>

WIKIPEDIA.(2024). [Decision tree learning-Gini impurity](https://en.wikipedia.org/wiki/Decision_tree_learning). Retrieved March 11, 2025, from https://en.wikipedia.org/wiki/Decision_tree_learning